

# Reti e Laboratorio III Modulo Laboratorio III AA. 2023-2024

docente: Laura Ricci

laura.ricci@unipi.it

Lezione 2

ThreadPoolExecutor, ScheduledPool, BlockingQueues 28/9/2023

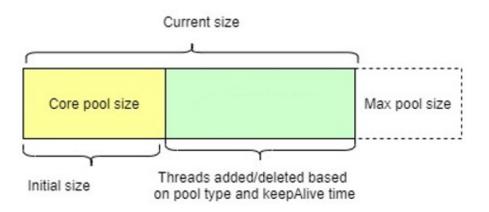


## THREAD POOL EXECUTOR

- il costruttore più generale: consente la personalizzazione della politica di gestione del pool
- CorePoolSize, MaximumPoolSize, keepAliveTime controllano la gestione dei thread del pool
- workqueue è una struttura dati necessaria per memorizzare gli eventuali tasks in attesa di esecuzione



## THREAD POOL EXECUTOR



- core: nucleo minimo di thread attivi nel pool
- i thread del core possono essere attivati
  - tutti al momento della creazione del pool: PrestartAllCoreThreads( )
  - "on demand", al momento della sottomissione di un nuovo task, anche se qualche thread già creato del core è inattivo.

obiettivo: riempire il pool prima possibile.

quando tutti i threads sono stati creati, la politica cambia



# THREAD POOL EXECUTOR: ELASTICITA'

Keep Alive Time: per i thread non appartenenti al core

- si considera il timeout T specificato al momento della costruzione del ThreadPool mediante la definizione di
  - un valore (es: 50000)
  - l'unità di misura utilizzata (es: TimeUnit. MILLISECONDS)
- se un thread è inattivo e se nessun task viene sottomesso entro T, il thread termina la sua esecuzione, riducendo così il numero di threads del pool
- la dimensione del ThreadPool non scende mai sotto Core pool size
  - unica eccezione: allowCoreThreadTimeOut(boolean value) invocato con il parametro settato a true

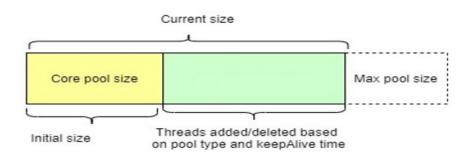


## THREAD POOL EXECUTOR: RIASSUNTO

se tutti i thread del core sono già stati creati e viene sottomesso un nuovo task:

- se un thread del core è inattivo, il task viene assegnato ad esso
  - se tutti i thread del core stanno eseguendo un task e la coda non è piena, il nuovo task viene inserito nella coda: i task verranno quindi poi prelevati dalla coda ed inviati ai thread disponibili
- se tutti i thread del core stanno eseguendo un task e la coda è piena
  - si crea un nuovo thread attivando così k thread,

- se coda è piena e sono attivi MaxPoolSize threads
  - il task viene respinto





# **THREAD POOL EXECUTOR: PARAMETRI**

Parameter	Туре	Meaning		
corePoolSize	int	Minimum/Base size of the pool		
maxPoolSize	int	Maximum size of the pool		
keepAliveTime + unit	long	Time to keep an idle thread alive (after which it is killed)		
workQueue	BlockingQueue	Queue to store the tasks from which threads fetch them		
handler	RejectedExecutionHandler	Callback to use when tasks submitted are rejected		



# **THREAD POOL EXECUTOR: ISTANZE**

PARAMETER	FIXEDTHREADPOOL	CACHEDTHREADPOOL	
CorePoolSize	Valore passato nel costruttore	0	
MaxPoolSize	stesso valore di CorePoolSize	Integer.MAXVALUE	
KeepAlive	0 Secondi	60 secondi	

```
public static ExecutorService newFixedThreadPool(int nThreads) {
    return new ThreadPoolExecutor(nThreads, nThreads, 0L, TimeUnit.MILLISECONDS,....)

public static ExecutorService newCachedThreadPool() {
    return new ThreadPoolExecutor(0, Integer.MAX_VALUE, 60L,TimeUnit.SECONDS,....);
```

 KeepAlive= 0 secondi corrisponde a "KeepAlive non significativo", il thread non viene mai disattivato



# ISTANZE DI THREADPOOLEXECUTOR

POOL	QUEUE TYPE	WHY?		
FixedThreadPool	LinkedBlockingQueue	Threads are limited, thus unbounded queue to store tasks Note: since queue can never become full, new threads are never created		
CachedThreadPool	SynchronousQueue	Threads are unbounded, thus no need to store the tasks. Create the new thread and give it directly the task		
Custom (ThreadPoolExecutor)	ArrayBlockingQueue	Bounded queue to store the tasks. If queue gets full, a new task is created (as long as count is less than MaxPoolSize)		

```
public static ExecutorService newFixedThreadPool(int nThreads) {
    return new ThreadPoolExecutor(nThreads, nThreads, 0L, TimeUnit.MILLISECONDS,....)

public static ExecutorService newCachedThreadPool() {
    return new ThreadPoolExecutor(0, Integer.MAX_VALUE, 60L,TimeUnit.SECONDS,....);
```

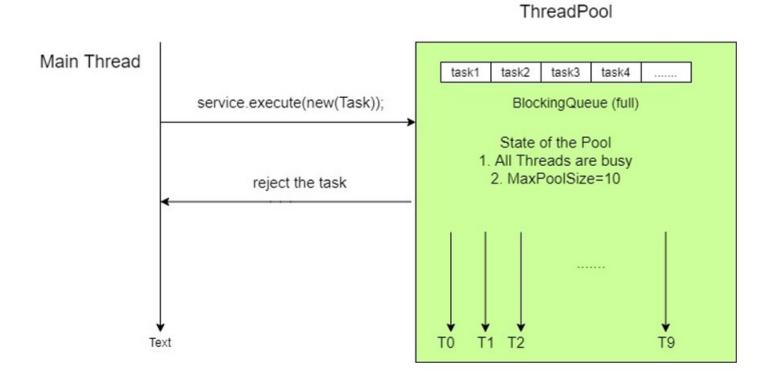


# **ALTRI TIPI DI THREAD POOL**

- Single Threaded Executor
  - un singolo thread
  - equivalente ad invocare un FixedThreadPool di dimensione I
  - utilizzo: assicurare che i thread del pool vengano eseguiti nell'ordine con cui si trovano in coda (sequenzialmente), però riutilizzando lo stesso thread
  - SingleThreadExecutor
- Scheduled Thread Pool
  - distanziare esecuzione dei task con un certo delay
  - task periodici



# **THREADPOOL: REJECTION**



# **THREADPOOL: REJECTION HANDLER**

- come viene gestito il rifiuto di un task? E' possibile
- scegliere esplicitamente una "rejection policy" al momento della creazione del task
  - AbortPolicy: politica di default, consiste nel sollevare RejectedExecutionException
  - DiscardPolicy, DiscardOldestPolicy,
     CallerRunsPolicy: altre politiche predefinite (vedere API):
- definire un custom rejection handler implementando l'interfaccia RejectExecutionHandler ed il metodo rejectedExecution



# **THREADPOOL: REJECTION HANDLER**

```
import java.util.concurrent.*;
public class RejectedException {
public static void main (String[] args )
    {ExecutorService service
           = new ThreadPoolExecutor(10, 12, 120, TimeUnit.SECONDS,
                       new ArrayBlockingQueue<Runnable>(3));
   for (int i=0; i<20; i++)
         try {
              service.execute(new Task(i));
         } catch (RejectedExecutionException e)
            {System.out.println("task rejected"+e.getMessage());}
         }}
```



## **EXECUTOR LIFECYCLE**

- la JVM termina la sua esecuzione quando tutti i thread (non demoni) terminano la loro esecuzione
- è necessario analizzare il concetto di terminazione, nel caso di Executor
   Service poichè
  - i tasks vengono eseguito in modo asincrono rispetto alla loro sottomissione.
  - in un certo istante, alcuni task sottomessi precedentemente possono essere completati, alcuni in esecuzione, alcuni in coda.
- poichè alcuni threads possono essere sempre attivi, JAVA mette a disposizione dell'utente alcuni metodi che permettono di terminare l'esecuzione del pool

## **EXECUTORS: TERMINAZIONE GRADUALE**

- la terminazione può avvenire
  - in modo graduale: "finisci ciò che hai iniziato, ma non iniziare nuovi tasks"
  - in modo istantaneo. "stacca la spina immediatamente"
- shutdown() "terminazione graduale": inizia la terminazione
  - nessun task viene accettato dopo che è stata invocata.
  - tutti i tasks sottomessi in precedenza e non ancora terminati vengono eseguiti, compresi quelli accodati, la cui esecuzione non è ancora iniziata

```
service.shutdown();
// throw RejectionExecutionException on a new task submission
service.isShutdown();
// return true is shutdown has begun
service.isTerminated();
// return true if all tasks are completed, including queued ones
service. awaitTermination(long timeout, TimeUnit unit)
// block until all tasks are completed or if timeout occurs
```



## **EXECUTORS: TERMINAZIONE IMMEDIATA**

```
List <Runnable> runnables = service.shutdownNow();
```

- non accetta ulteriori tasks ed elimina i tasks non ancora iniziati
  - restituisce una lista dei tasks che sono stati eliminati dalla coda
- implementazione best effort: tenta di terminare l'esecuzione dei thread che stanno eseguendo i tasks, inviando una interruzione ai thread in esecuzione nel pool
  - non garantisce la terminazione immediata dei threads del pool
  - se un thread non risponde all'interruzione non termina
- se sottometto il seguente task al pool

```
public class ThreadLoop implements Runnable {
    public ThreadLoop(){};
    public void run(){while (true) { } } }
```



e poi invoco la shutdownNow(), osservate che il programma non termina

# **DETERMINARE LA DIMENSIONE DEL THREADPOOL**

- la dimensione ideale per il numero di threads in un ThreadPool non è facile da determinare
- dato il numero di core della macchina, dipende dal tipo di task da eseguire
- CPU bound tasks
  - task che devono eseguire calcoli complessi. Un esempio: inversione parziale di un hash, come le PoW di Bitcoin ed Ethereum
  - in questo scenario, idealmente, la dimensione ottimale del pool = numero di
     CPU cores
- IO bound tasks
  - accesso a database, accesso alla rete
  - spesso bloccati in attesa del completamento di operazioni del SO
  - un numero di thread maggiore del numero di CPU cores può aumentare le performance della applicazione



## DETERMINARE LA DIMENSIONE DEL THREADPOOL

```
import java.util.concurrent.ExecutorService;
import java.util.concurrent.Executors;
public class CPUIntensiveTask implements Runnable {
                   public void run() {
                     // eseguo la PoW }
public class ThreadDimensioning {
    public static void main (String [] args) {
    // get count of available cores
    int coreCount = Runtime.getRuntime().availableProcessors();
   System.out.println(coreCount);
    ExecutorService service = Executors.newFixedThreadPool(coreCount);
    // submit the tasks for execution
    for (int i=0; i< 100; i++) {
       service.execute(new CPUIntensiveTask());
      } }
```



# DETERMINARE LA DIMENSIONE DEL THREADPOOL

TIPO DI TASK	DIMENSIONE IDEALE POOL	CONSIDERAZIONI		
CPU Intensive	CPU Core Count	Quante altre applicazioni sono in esecuzione sulla stessa CPU		
IO Intensive	High	Numero esatto dipende anche dalla frequenza con cui i task vengono sottomessi e dal tempo medio di attesa. Troppi thread possono aumentare la memory pressure		



# **ALTRI TIPI DI THREAD POOL**

- Single Threaded Executor
  - un singolo thread
  - equivalente ad invocare un FixedThreadPool di dimensione I
  - utilizzo: assicurare che i task vengano eseguiti nell'ordine con cui si trovano in coda (sequenzialmente), ma con riutizzo di thread
- Scheduled Thread Pool
  - distanziare esecuzione dei task con un certo delay
  - task periodici



## **SCHEDULED EXECUTOR SERVICE**

- l'interfaccia ScheduledExecutorService da la possibiltà di schedulare un task
  - dopo un certo periodo di tempo (delay)
  - periodicamente
- schedule(Runnable command, long delay, TimeUnit unit)
  - esegue un task Runnable (o Callable) dopo un certo intervallo di tempo
- scheduleAtFixedRate(Runnable command, long initialDelay, long delay, TimeUnit unit)
  - esegue un task dopo un intervallo iniziale, poi lo ripete periodicamente.
  - se il tempo di esecuzione del task è maggiore del periodo specificato, le sue seguenti esecuzioni possono essere ritardate.
- scheduleWithFixedDelay(Runnable command, long initialDelay, long delay, TimeUnit unit)
  - esegue un task dopo un intervallo iniziale, poi lo ripete periodicamente con un intervallo dato tra la terminazione di una esecuzione e l'inizio della successiva



## **SCHEDULED EXECUTOR SERVICE**

#### scheduleAtFixedRate

start	[]++++		][			][
init delay	execution time idle	execution time	П	execution	time	11
	period	period	П	period	extra	11

# scheduleWithFixedDelay

## **UN BEEP PERIODICO...**

```
import java.util.concurrent.*;
import java.awt.*;
public class BeepClockS implements Runnable {
   public void run() {
         Toolkit.getDefaultToolkit().beep();
         }
   public static void main(String[] args) {
        ScheduledExecutorService scheduler
                               = Executors.newSingleThreadScheduledExecutor();
        Runnable task = new BeepClockS();
        int initialDelay = 4;
        int periodicDelay = 2;
        scheduler.scheduleAtFixedRate(task, initialDelay, periodicDelay,
                                                         TimeUnit.SECONDS);}}
```



## **UN TASK "COUNTDOWN"**

```
public class CountDownClock implements Runnable {
   private String clockName;
   public CountDownClock(String clockName) {
       this.clockName = clockName;
   public void run() {
       String threadName = Thread.currentThread().getName();
       for (int i = 5; i >= 0; i--) {
           System.out.printf("%s -> %s: %d\n", threadName, clockName, i);
           try {
               Thread.sleep(1000);
            } catch (InterruptedException ex) {
                            ex.printStackTrace();
```



# **COUNTDOWN SCAGLIONATI NEL TEMPO**

```
import java.util.concurrent.*;
public class ConcurrentScheduledTaskExample {
    public static void main(String[] args) {
        ScheduledExecutorService scheduler = Executors.newScheduledThreadPool(3);
        CountDownClock clock1 = new CountDownClock("A");
        CountDownClock clock2 = new CountDownClock("B");
        CountDownClock clock3 = new CountDownClock("C");
        scheduler.scheduleWithFixedDelay(clock1, 3, 10, TimeUnit.SECONDS);
        scheduler.scheduleWithFixedDelay(clock2, 3, 15, TimeUnit.SECONDS);
        scheduler.scheduleWithFixedDelay(clock3, 3, 20, TimeUnit.SECONDS);
     }
```



# **CONDIVIDERE RISORSETRATHREADS**

- un insieme di thread vogliono condividere una risorsa.
  - più thread accedono concorrentemente allo stesso file, alla stessa parte di un database o di una struttura di memoria
- l'accesso non controllato a risorse condivise può provocare situazioni di errore ed inconsistenze.
  - race conditions
- sezione critica: blocco di codice a cui si effettua l'accesso ad una risorsa condivisa e che deve essere eseguito da un thread per volta
- necessario implementare classi thread safe
  - il codice dei metodi della classe può essere utilizzato/condiviso in un ambiente concorrente senza provocare inconsistenze/comportamenti inaspettati

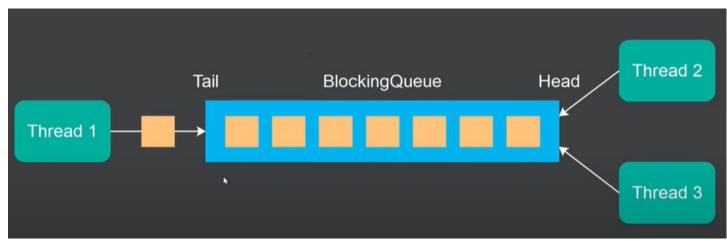


# **ALTERNATIVE PER DEFINIRE CLASSITHREAD SAFE**

- alternative per definire classi thread safe: usare
  - classi thread safe predefinite
    - concurrent-aware interfaces
      - Interfaces: Blocking Queue, TransferQueue, Blocking Dequeue, ConcurrentMap, ConcurrentNavigable Map
    - concurrent-aware classes
      - LinkedBlockingQueue
      - ArrayBlockingQueue
      - PriorityBlockingQueue
      - DelayQueue
      - SynhronousQueue
      - CopyOnWriteArrayList
      - CopyOnWriteArraySet
      - ConcurrentHahsMap
  - i monitor
  - le lock a basso livello (non le vedremo)



# **JAVA BLOCKING QUEUE**



- BlockingQueue (java.util.concurrent): una JAVA interface che rappresenta una coda (inserimento alla fine, estrazione all'inizio)
- ...ma quale è la differenza con la interface Queue < E > (package JAVA.UTIL)?
  - pensata per essere utilizzata in un ambiente multithreaded
  - permettere una corretta sincronizzazione tra i thread che inseriscono e quelli che eliminano elementi dalla coda
    - Thread1 si blocca se la coda è piena, Thread2 e Thread3 se è vuota
  - implementa una corretta sincronizzazione tra thread



# **BLOCKING QUEUE: IMPLEMENTAZIONI**

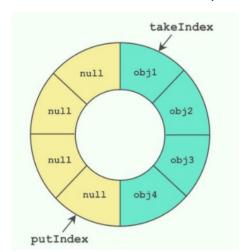
```
import java.util.concurrent.ArrayBlockingQueue;
import java.util.concurrent.BlockingQueue;
                                                                            Iterable
                                                                                               Interface
import java.util.concurrent.LinkedBlockingQueue;
                                                                               extends
                                                                                               Class
                                                                            Collection
public class BlockingQueueExample {
                                                                               extends
       public static void main(String[] args)
                                                                             Queue
            {BlockingQueue arrayBlockingQueue =
                                                                                extends
                      ArrayBlockingQueue(3);
                                                                           BlockingQueue
                                                                                      implements
              BlockingQueue linkedBlockingQueue =
                      LinkedBlockingQueue();
                new
                                                                ArrayBlockingQueue
                                                                                   LinkedBlockingQueue
             // java.util.concurrent.DelayQueue
             // java.util.concurrent.LinkedTranserQueue
                java.util.concurrent.PriorityBlockingQueue
             // java.util.concurrent.SynchronousQueue
             }}
```

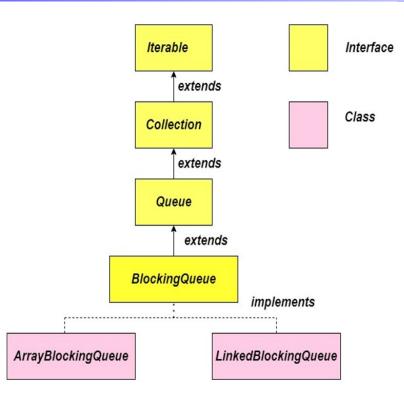


# **QUALI CODE UTILIZZEREMO MAGGIORMENTE?**

## **ArrayBlockingQueue**

- dimensione limitata, definita in fase di inizializzazione
- memorizza gli elementi all'interno di un oggetto Array
  - nessun ulteriore oggetto creato
  - non sono possibili inserzioni/rimozioni in parallelo
  - una sola lock per tutta la struttura)



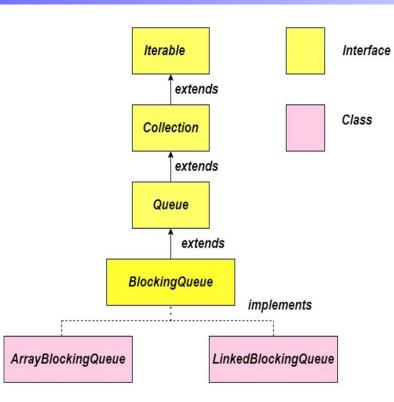


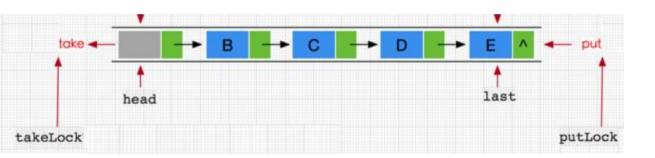


# **E QUALI CODE UTILIZZEREMO MAGGIORMENTE?**

## **LinkedBlockingQueue**

- può essere limitata o illimitata, se illimitata
   dimensione = Integer.MAX\_VALUE.
- mantiene gli elementi in una LinkedList
  - maggior occupazione di memoria
  - un nuovo oggetto per ogni inserzione
- possibili inserzioni ed estrazioni concorrenti
  (lock separate per lettura e scrittura), maggior
  throughput







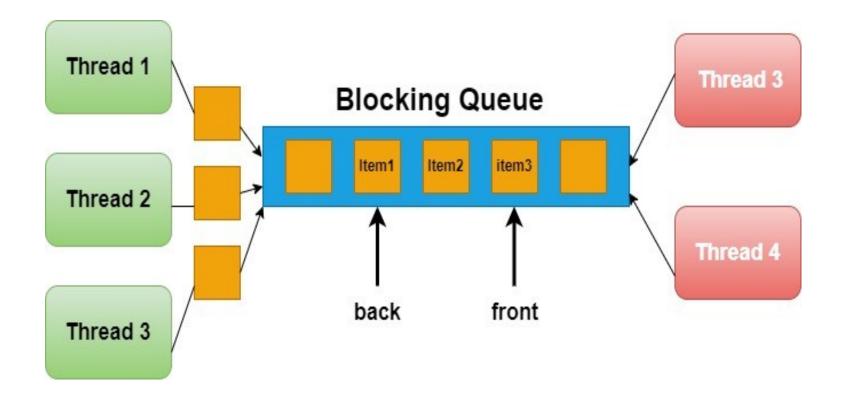
# **BLOCKINGQUEUE: OPERAZIONI**

- 4 metodi diversi, rispettivamente, per inserire, rimuovere, esaminare un elemento della coda
- ogni metodo ha un comportamento diverso relativamente al caso in cui l'operazione non possa essere svolta

	Throws Exception	Special Value	Blocks	Times Out
Insert	add(o)	offer(o)	put(o)	offer(o, timeout, timeunit)
Remove	remove(o)	poll()	take()	poll(timeout, timeunit)
Examine	element()	peek()		



# IL PROBLEMA DEL PRODUTTORE CONSUMATORE





32

# IL PROBLEMA DEL PRODUTTORE CONSUMATORE

- un classico problema che descrive due (o più thread) che condividono un buffer, di dimensione fissata, usato come una coda
- specifiche
  - il produttore P produce un nuovo valore, lo inserisce nel buffer e torna a produrre valori
  - il consumatore C consuma il valore (lo rimuove dal buffer) e torna a richiedere valori
  - garantire che il produttore non provi ad aggiungere un dato nelle coda se è piena ed il consumatore non provi a rimuovere un dato da una coda vuota
- vincoli di sincronizzazione
  - due thread non devono accedere contamporaneamente alla coda
  - un produttore si deve bloccare se la coda è piena
  - un consumatore si deve bloccare se la coda è vuota



# PRODUTTORE CONSUMATORE: SINCRONIZZAZIONE

- l'interazione esplicita tra threads avviene in JAVA mediante l'utilizzo di oggetti condivisi
  - la coda che memorizza i messaggi scambiati tra P e C è condivisa
- necessari costrutti per sospendere un thread T quando una condizione non è verificata e riattivare T quando diventa vera
  - il produttore si sospende se la coda è piena
  - si riattiva quando c'è una posizione libera
- due tipi di sincronizzazione:
  - implicita: la mutua esclusione sull'oggetto condiviso è garantita dall'uso di lock (implicite o esplicite)
  - esplicita: occorrono altri meccanismi



## PRODUTTORE/CONSUMATORE CON BLOCKINQUEUES

```
import java.util.concurrent.BlockingQueue;
import java.util.concurrent.ArrayBlockingQueue;
public class ProducerConsumerExample {
     public static void main(String[] args) {
           BlockingQueue<String> blockingQueue =
                                new ArrayBlockingQueue<String>(3);
           Producer producer = new Producer(blockingQueue);
           Consumer consumer = new Consumer(blockingQueue);
           Thread producerThread = new Thread (producer);
           Thread consumerThread = new Thread(consumer);
           producerThread.start();
                                                        il riferimento alla
           consumerThread.start(); } }
                                                        struttura dati condivisa si
                                                        passa ad entrambi i thread
```



#### PRODUTTORE/CONSUMATORE CON CONCURRENT COLLECTIONS

```
import java.util.concurrent.BlockingQueue;
public class Producer implements Runnable {
     BlockingQueue <String> blockingQueue = null;
     public Producer (BlockingQueue<String> queue) {
            this.blockingQueue = queue; }
     public void run() {
        while (true) {
            long timeMillis = System.currentTimeMillis();
            try {
                this.blockingQueue.put("" + timeMillis);
            } catch (InterruptedException e) {
            System.out.println("Producer was interrupted"); }
            sleep(1000); }}
     private static void sleep(long timeMillis) {
          try { Thread.sleep(timeMillis);
                } catch(InterruptedException e) {e.printStackTrace()}} }
```



#### PRODUTTORE/CONSUMATORE CON CONCURRENT COLLECTIONS

```
import java.util.concurrent.BlockingQueue;
public class Consumer implements Runnable {
     BlockingQueue<String> blockingQueue = null;
     public Consumer (BlockingQueue <String> queue) {
       this.blockingQueue = queue; }
     public void run() {
         while (true) {
            try {
                String element =
                        this.blockingQueue.take();
                System.out.println("consumed: "+ element);
            } catch (InterruptedException e) {e.printStackTrace();}
```

# **ASSIGNMENT 2: SIMULAZIONE UFFICIO POSTALE**

- simulare il flusso di clienti in un ufficio postale che ha 4 sportelli. Nell'ufficio esiste:
  - un'ampia sala d'attesa in cui ogni persona può entrare liberamente. Quando entra, ogni persona prende il numero dalla numeratrice e aspetta il proprio turno in questa sala.
  - una seconda sala, meno ampia, posta davanti agli sportelli, in cui si può entrare solo a gruppi di k persone
- una persona si mette quindi prima in coda nella prima sala, poi passa nella seconda sala.
- ogni persona impiega un tempo differente per la propria operazione allo sportello. Una volta terminata l'operazione, la persona esce dall'ufficio



# **ASSIGNMENT 2: SIMULAZIONE UFFICIO POSTALE**

- Scrivere un programma in cui:
  - l'ufficio viene modellato come una classe JAVA, in cui viene attivato un ThreadPool di dimensione uguale al numero degli sportelli
  - la coda delle persone presenti nella sala d'attesa è gestita esplicitamente dal programma
  - la seconda coda (davanti agli sportelli) è quella gestita implicitamente dal ThreadPool
  - ogni persona viene modellata come un task, un task che deve essere assegnato ad uno dei thread associati agli sportelli
  - si preveda di far entrare tutte le persone nell'ufficio postale, all'inizio del programma
- Facoltativo: prevedere il caso di un flusso continuo di clienti e la possibilità che l'operatore chiuda lo sportello stesso dopo che in un certo intervallo di tempo non si presentano clienti al suo sportello.

